

Laboratorio 1 – Data Mining

Esercizio 1: Compressione di immagini attraverso i seguenti passi

- Scegliere una (propria) foto o una qualsiasi immagine,
- Leggerla su Matlab/Python,
- Trasformare la foto in bianco e nero,
- Calcolare la SVD ridotta e vedere come migliora l'approssimazione aumentando il suo rango,
- Mostrare andamento dell'errore al variare del rango dell'approssimazione,
- Mostrare i valori singolari,
- Identificare una strategia per scegliere a-priori il rango da selezionare.

Esercizio 2: Creare tre esempi artificiali dove il coefficiente di determinazione R^2 sarà $R^2 \approx \{0, 0.5, 1\}$. Fare un plot per ogni dataset con la corrispondente retta di regressione. (Vedere esempio fatto a lezione).

Esercizio 3: Scaricare il dataset `Companies.mat` dal moodle. Si trova una descrizione del dataset nel file `Companies.txt`. L'obiettivo è valutare il valore di mercato dell'azienda (market value). Estrarre, quindi, i dati appropriati per definire $X \in \mathbb{R}^{n \times p}$, con $n = 79$, $p = 5$, e $y \in \mathbb{R}^n$, e risolvere

$$\min_{\beta \in \mathbb{R}^{p+1}} \|y - [1, X]\beta\|^2 \quad (1)$$

in tre modi diversi:

- Equazioni normali (attenzione!!!);
- QR;
- SVD.

Per la soluzione ottenuta tramite il metodo QR, riprodurre i grafici mostrati a lezione e calcolare i coefficienti di determinazione per i tre metodi. Provare a *giocare* con il dataset per ridurre, ad esempio, l'errore.

Esercizio 4 (Predizione della variabile risposta). Costruire un nuovo dataset (y_{new}, X_{new}) ottenuto dal dataset originale eliminando l'ultimo insieme di dati (relativo all'azienda FW Woolworth). Calcolare un nuovo modello di regressione lineare (cioè un nuovo β_{new}) utilizzando (y_{new}, X_{new}) . Quindi, con il modello di regressione, usare le variabili predittive relative a FW Woolworth e il nuovo β_{new} costruito, per predire il valore di mercato (Market Value) di FW Woolworth. Confrontare il valore stimato con il valore del dataset. Possiamo migliorare il risultato ottenuto?

Esercizio 5: Scaricare il dataset `A_med.mat` dal moodle. Si tratta di una matrice di dimensione 5735×1033 che contiene, in ciascuna colonna, documenti di argomento medico. Ogni elemento non nullo di una colonna corrisponde al numero di volte che una determinata parola compare in quel documento. Per la prima colonna di `A_med.mat`, generare il grafico mostrato in Figura 1 qui sotto utilizzando il dizionario `dict_med.mat`.




Figura 1: Frequenze delle diverse parole nel documento per y .

Esercizio 6: Implementare il metodo iterativo (visto a lezione) che, dato il corretto insieme di input, risolve il problema dei minimi quadrati (1). Riportare l'andamento della norma relativa del residuo del metodo.

Per testare la funzione, si consideri y uguale alla prima colonna di `A_med.mat` e X uguale alle restanti 1032 colonne.

Risolvere, successivamente, (1) utilizzando i metodi diretti. Confrontare i risultati ed i tempi di calcolo.

Esercizio 7:[opzionale] Cercate un dataset su qualsiasi tematica e impostate un problema di regressione lineare.