

Laboratorio 2 – Data Mining

Esercizio 1: Considerare il dataset Detroit.txt (e successivamente EgyptianSkulls.txt). Determinare quante componenti principali sono necessarie per rappresentare 80-90% del dataset. Successivamente, calcolarle e stampare a schermo le nuove variabili e confrontare le componenti principali rispetto alle variabili originali. Calcolare, il coefficiente di correlazione tra le nuove variabili x_k e le nuove y_i definito come segue

$$r_{y_i, x_k} = \frac{Cov(y_i, x_k)}{\sqrt{Var(y_i)}\sqrt{Var(x_k)}}$$

Ripetere la stessa analisi dopo aver standardizzato le variabili.

Esercizio 2: Preparare due script `mp.m` e `omp.m` che implementano l'algoritmo Matching Pursuit (MP) e Orthogonal Matching Pursuit (OMP), rispettivamente.

Per testare le funzioni scaricare il materiale nella cartella "fashion_all". Lo script principale `script_OMP.m` legge le immagini contenute nel dataset Fashion MNIST dataset. Il goal è di definire un dizionario $D \in \mathbb{R}^{784 \times n_D}$ selezionando in maniera random n_D immagini dall'intero dataset; n_D viene scelto dall'utente. Quindi per un'immagine assegnata $y \in \mathbb{R}^{784}$, calcolare il vettore sparso $x \in \mathbb{R}^{n_D}$ tale che

$$y \approx Dx, \quad \|x\|_0 \leq k,$$

dove il livello di sparsità viene scelto dall'utente. Calcolare x con MP e OMP e poi confrontare i risultati.

Esercizio 3:[opzionale] Cercate un dataset su qualsiasi tematica e impostate un problema come nell'esercizio 2.